

RBD 技术白皮书

资料版本：5W100-20221127

Copyright © 2022 新华三技术有限公司 版权所有，保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本档内容的部分或全部，并不得以任何形式传播。

除新华三技术有限公司的商标外，本手册中出现的其它公司的商标、产品标识及商品名称，由各自权利人拥有。

本文中的内容为通用性技术信息，某些信息可能不适用于您所购买的产品。

目 录

1 概述.....	1
1.1 RBD 介绍.....	1
1.2 技术优势	1
2 技术实现	2
2.1 名词介绍	2
2.2 RBD 的存储过程.....	2
2.3 RBD 的 IO 流程	4
2.4 云平台上使用 RBD 流程	5


1 概述

1.1 RBD介绍

RBD(RADOS Block Device)是 Ceph 分布式存储系统提供的块存储设备接口，其中 RADOS (Realable Autonomic Distributed Object Store)即可靠、自治、分布式对象存储，是 Ceph 的核心系统之一，可在动态变化和异质结构的存储设备之上提供一种稳定、可扩展、高性能的单一逻辑对象存储接口并实现节点的自适应、自管理。

RBD 在 Ceph 架构中的位置如[图 1](#)所示，作为 Ceph 对外提供的三大高层应用接口之一，其通常被用于虚拟化的环境下为虚拟机创建存储卷，也可以被映射、格式化，像磁盘一样挂载到服务器上使用。Red Hat 已将 RBD 驱动集成在 KVM/QEMU 中，以提高虚拟机访问性能。

图1 Ceph 架构中的 RBD



1.2 技术优势

具体来说，虚拟机在云上使用 RBD 有如下优势：

- 虚拟机与 RBD 块设备对接时，可以避免 OCFS2 集群共享文件系统和存储协议带来的 IO 性能损耗。
- 相对于裸设备映射，可支持在线主机迁移和离线快照。

2 技术实现

2.1 名词介绍

本文档涉及到的 Ceph 中的专有名词介绍如下：

- **OSD (Object Storage Device)**: Ceph 存储集群的重要组件，可被抽象为系统部分和守护进程两部分，系统部分指硬盘、内存、处理器等物理结构，守护进程指 **OSD daemon**，其负责将数据以对象的形式存储到每个节点的物理磁盘上，向 **monitor** 提供监控信息，与 **Client** 通信等工作。
- **Monitor**: 监控节点，监控集群的全局状态，维护集群的 **Cluster Map** 二进制表，保证集群数据的一致性。
- **object**: RADOS 所看到的“对象”，Ceph 存储中的最小存储单元，其大小由 RADOS 限定，默认是 4MB。
- **PG (Placement Group)**: 归置组，对 **object** 的存储进行组织和位置映射，一个 PG 会组织若干个 **object**，同时，一个 PG 也会映射到 n 个 OSD 上， $n \geq 2$ 。
- **Pool**: Ceph 上创建的存储池，是对 Ceph 集群的逻辑划分，主要设置存储对象的权限、备份数目、PG 数等属性。


2.2 RBD的存储过程

在 Ceph 中无论使用哪种存储方式，当数据要存储到 Ceph 分布式存储集群时，存储数据都会被分割成一个或多个 **object**，再由 PG 对这些 **object** 进行管理、计算映射到某一个 PG 中，之后 PG 也需要通过 CRUSH 算法映射到 OSD 中进行存储，如果设置的是两副本，则每一个 PG 会映射到两个 OSD 中，保证数据的冗余性。

对于云上使用 RBD 存储的虚拟机来说，客户端需要通过 **librbd** 库来访问管理块设备，其数据层次映射关系如[图 2](#) 所示。分为以下几步：


- (1) 在 RBD 服务端创建 **pool**，创建 **pool** 时会指定其中 PG 的数量和保存数据的副本数。
- (2) 客户端对有写请求时会在这个 **pool** 中创建一个 RBD 设备。
- (3) 对这个 RBD 块设备进行切块，分为一个或多个 **object** 对象，每个 **object** 都有一个 **object id** 号。
- (4) 由 Ceph 系统指定的函数对 **object id** 进行计算映射，得到 **object** 所对应的 PG 的 PG id 号。
- (5) 将 PG 通过 CRUSH 算法映射到实际的数据存储单元 OSD，3 副本时会分别寻找三个 **osd**，并把这个 **object** 分别保存在这三个 **osd** 上，之后会生成一个名为 **rbd0.object1.file** 的镜像文件。

图2 RBD 到 OSD 的映射关系



经过 pool, object, PG 的层层映射关系, 在 PG 这一层中已经知道了存储数据的 OSD 的所在位置和主从关系, 这时客户端即可与 primary OSD 建立 SOCKET 通信, 将写入的数据传给 primary OSD, 之后再由 primary OSD 将数据发送给其它 OSD 数据节点。当 primary OSD 确信自身以及其它的 OSD 副本写入完成之后, 才会向 Client 确认写入操作完成。

图3 数据写入流程




2.3 RBD的IO流程

在 Ceph 集群中，由 monitor 负责集群中所有 OSD 状态的发现与记录，并负责形成 Cluster map 信息，扩散至全体 OSD 以及 client。OSD 使用 Cluster map 进行数据的维护，而 Client 使用 Cluster map 进行数据的寻址。

在正常情况下，其 IO 流程如下：


- (1) client 创建 cluster handler（集群处理信息）。
- (2) client 读取配置文件。
- (3) client 连接上 monitor，获取 cluster map 信息。
- (4) client 读写 io 根据 cluster map 中记录的信息请求对应的主 OSD 数据节点。
- (5) 主 OSD 数据节点同时写入另外两个副本节点数据。
- (6) 等待主节点以及另外两个副本节点写完数据状态。
- (7) 主节点及副本节点写入状态都成功后，返回给 client，io 写入完成。

图4 正常 IO 流程



如果新加入的 OSD4 代替了原先的 primary OSD1，由于 OSD4 上未创建 PG，不存在数据，那么 PG 上的 I/O 无法进行，此时 monitor 监控节点会因为 OSD 4 上没有 PG 数据上报而告知系统中的另外一个 OSD 临时成为 primary 节点。Client 会直接与临时 OSD 通信进行读写，之后等待 OSD4 数据同步完成，原先的临时 primary OSD 会交出主角色，让 OSD4 成为主节点，自身降为复制节点。

图5 新主节点 IO 流程



2.4 云平台上使用RBD流程

RBD 可以为 KVM 等虚拟化技术和云服务提供高性能和无限可扩展性的存储后端，并基于 Libvirt 和 QEMU 应用程序与 RBD 进行集成，客户端基于 librbd 库即可将 RADOS 存储集群用作块设备。以在 CAS 云计算管理平台上的使用 RBD 存储作为虚拟机的虚拟磁盘为例，其流程如图 5 所示。

- (1) 在分布式存储集群中创建硬盘池。
- (2) 在 CAS 上面添加分布式存储。
- (3) 主机安装启动 RBD Client 客户端。
- (4) 云平台上创建 RBD 网络存储池。
- (5) 在主机上添加 RBD 网络存储池。
- (6) 在 RBD 网络存储池中创建存储卷，挂载给虚拟机使用。

图6 CAS 虚拟化平台使用 RBD 存储的过程

