

H3C CAS 云计算管理平台

虚拟机在线迁移特性技术白皮书

资料版本：5W100-20221125

Copyright © 2022 新华三技术有限公司 版权所有，保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

除新华三技术有限公司的商标外，本手册中出现的其它公司的商标、产品标识及商品名称，由各自权利人拥有。

本文档中的信息可能变动，恕不另行通知。

目 录

1 概述.....	1
2 虚拟机在线迁移技术实现.....	1
2.1 概念介绍	1
2.2 预拷贝内存（Pre-copy）实现原理	2
2.3 内存后拷贝（Postcopy）实现原理.....	3
3 H3C CAS 实现的技术特色	3

1 概述

迁移虚拟机是指更改虚拟机的运行载体，包括计算资源和存储资源，如更改虚拟机运行的主机、更改虚拟机磁盘（镜像文件）所在的存储池等。

根据虚拟机的状态可分为在线迁移和离线迁移两种方式：

- 在线迁移是指迁移运行状态的虚拟机。在进行在线迁移虚拟机之前，请确保目的主机的内存充足，否则将会导致虚拟机迁移失败。
- 离线迁移是指迁移关闭状态的虚拟机。

CAS 提供了更改主机、更改存储数据、更改主机和存储数据三种手工迁移方式。本文主要介绍在线虚拟机更改主机的两种实现方法。



说明

虚拟机迁移操作的相关注意事项，请参考联机帮助文档。

2 虚拟机在线迁移技术实现

在线虚拟机更改主机时，由于迁移过程中虚拟机仍在运行，所以需要妥善处理虚拟机内存数据，保证虚拟机运行正常。常见的迁移方法有预拷贝内存（Pre-copy）和内存后拷贝（Postcopy），两者的主要区别是对于内存数据及脏页面处理的先后顺序不同。

- Pre-copy 是指将内存数据和其他配置等信息一同拷贝，再循环拷贝脏页面，迁移期间虚拟机仍在源端主机中运行。
- Postcopy 是指将其他配置信息先行拷贝，将必要信息拷贝至目的主机后拉起虚拟机，再由源端主机传输内存及脏页面数据。

在 CAS 中，默认使用预拷贝内存的方法进行迁移。但是当内存数据比较活跃时，脏页面数量大，循环查询、迁移的过程重复次数多，导致虚拟机迁移需时很长，因此增加了内存后拷贝的方法来规避该问题。

2.1 概念介绍

- 脏页面：在线虚拟机迁移时，由于其虚拟机仍在运行，所以会产生新的内存数据，在迁移时，没有被拷贝到目的虚拟机（所在主机）中的内存页面，则称为脏页面。
- 预拷贝内存相关概念：



说明

采用内存后拷贝方式迁移在线虚拟机时，无需设置迁移超时时长及自动收敛选项。

- 迁移超时时长：迁移在线虚拟机时，需要设置迁移超时时长。若超时时长到期后虚拟机还未完成迁移，则系统将暂停该虚拟机，以便其可以快速完成迁移；迁移完成后，再将该虚

虚拟机恢复为运行状态。默认为 5 分钟，设置为 0 表示不限制时长，系统将不会暂停虚拟机，在迁移过程中虚拟机始终处于运行状态。

- 自动收敛：开启自动收敛后，若虚拟机长时间未完成迁移，系统会降低 CPU 的使用，以加快迁移速度，尽量缩短迁移时长；但开启后可能会降低虚拟机性能。
- 内存后拷贝相关概念：
 - **page-fault**：缺页异常，是指当 CPU 执行进行的某个内存页面时，发现要访问的页在内存中不存在，导致进程中断。在内存后拷贝过程中，当目的虚拟机运行调用到还没从源端主机传输过来的内存数据时，会触发 **page-fault**。

2.2 预拷贝内存（Pre-copy）实现原理

预拷贝内存（Pre-copy）将内存数据循环发送至目的主机的虚拟机中。循环第一轮发送所有内存数据，后续每一轮发送上一轮预拷贝过程中的脏页面。最后一轮则为停机拷贝阶段，源端主机被挂起，停止内存更新，将脏页面整体拷贝到目的主机的虚拟机中上。

对于更新速度非常快的内存页面，每次循环过程都会产生脏数据，需要重复拷贝内存，同时也导致循环次数非常多，迁移的时间变长。针对这种情况，虚拟机迁移过程中一般会遵循如下三个原则：

- 集中原则：例如一个循环内的脏页面小于等于 50。
- 不扩散原则：一个循环内传输的脏页面少于新产生的脏页面。
- 有限循环原则：例如循环次数必须少于 30 次。

在具体实现上，采取了如下措施：

- 设置暂停机制：循环次数、效果、迁移时长受到控制，对每轮 **Pre-copy** 的效果进行计算，例如 **Pre-copy** 对于减少不一致内存数量的效果不显著、循环次数超过了上限、超过了限制时长时，循环将中止，进入停机拷贝阶段，暂停虚拟机使其不产生新的脏页面。
- 自动收敛：在被迁移虚拟机的内核设置一个内存访问的监控模块。在内存 **Pre-copy** 过程中，虚拟机的一个进程在一个被调度运行的期间，采用限制最多执行 40 次内存写操作、降低 CPU 频率等措施，直接限制了 **Pre-copy** 过程中内存变脏的速度，减少脏页面数量及产生速度，缺点是限制了虚拟机中的进程运行，会降低虚拟机性能。

预拷贝内存过程详解：

- (1) 系统验证目标主机的存储器和网络设置是否正确，并预保留目标主机的虚拟机所需资源。
- (2) 当虚拟机还在源端主机上运转时，第一个循环内将全部内存镜像复制到目标主机中。在这个过程中，CAS 会监视内存的所有变化。
- (3) 此后的循环中，检查上一个循环中内存是否发生了变化。如果发生了变化，那么 CAS 会将脏页面重新复制到目标主机中，并覆盖掉先前的内存页。在这个阶段，CAS 依然会继续监视内存的变化情况。
- (4) CAS 持续执行内存复制循环。随着循环次数的增加，所需要复制的脏页面就会明显减少，而复制所耗费的时间就会逐渐变短，那么内存就有可能没有足够的时间发生变化。
- (5) 当源端主机与目标主机之间的差异达到一定标准时，内存复制操作才会结束，同时暂停源系统。在源系统和目标系统都停机的情况下，将最后一个循环的脏页面和源系统设备的工作状态复制到目标主机。
- (6) 将存储从源系统上解锁，并锁定在目标系统上。启动目标虚拟机，并与存储资源和网络资源相连接。

2.3 内存后拷贝（Postcopy）实现原理

内存后拷贝（Postcopy）先把虚拟机现有的 CPU 状态、寄存器状态、non-pageable memory（不进行交换或移动的内存）等配置/信息传输到目的主机中，暂时不管脏页面，并迅速把虚拟机在目的主机启动起来。同时，源端主机也会动态的把剩余的内存数据推送到目的主机上。

但是当虚拟机运行调用到还没传输过来的内存数据时，会触发 page-fault。Postcopy 基于 userfault 机制，可以在用户空间中通过文件描述符 fd 获得 page-fault 信息。当虚拟机在目的主机上上调用到这些还未传输完成的内存时，userfault 可以到源端主机中把这些内存信息取出，并传输到目的主机，让虚拟机继续运行。

使用 Postcopy 不会受虚拟机内存更新速度快的影响，但迁移完成后如果需要大量读取内存数据，可能会频繁调用 userfault，这种情况会对源端主机和目的主机的迁移网络带宽带来压力，造成虚拟机性能下降，并且源端主机和目的主机间的网络异常会引起虚拟机异常。

3 H3C CAS 实现的技术特色

H3C CAS 中的虚拟机手工进行在线迁移时，默认使用 Pre-copy 方法进行迁移，在迁移时可选择设置迁移超时时长、启动自动收敛功能等方法，减少脏页面的产生，以便虚拟机可以顺利迁移；此外还支持对迁移过程中的数据进行加密，以及在更改主机的同时更改数据存储。

启用内存后拷贝功能后，则会使用 Postcopy 的方法进行迁移，加快虚拟机已的速度。